

# بسم الله الرحمن الرحيم



محمد عرفان زارع زردینی

۹۸۴۱۱۴۳۲

تمرین سری پنجم درس بینایی ماشین

# سوال 1)

References: Slides class

(الف)

محمد عمران زارع

در این بخش برای پاده بندی LBP روی تصویر به Padding نیاز هست. پیرامون تعداد Column & Row برای Padding و نحوه

در نظر گرفتن padding و نحوه اضافه کردن آن به تصویر را در نظر می گیریم.

برای در نظر گرفتن Reflection padding استفاده می کنیم. دلیل: با توجه به اینکه برای بررسی هر خانه به ۸ همسایه

نیاز داریم و اگر در لبه تصویر داده شده که در آنجا ۸ همسایه نیست پس برای بررسی و پاده سازی LBP به

تصویرمان به Padding می دهیم.

(ب)

Year:      Month:      Date:      ( )

۱۰	۱۰	۱۰	۱۰	۲۵	۲۵	۲۵	۲۵	۲۵	۲۵	۲۵	۱۲۴	۲۵	۲۵
۱۰	۱۰	۱۰	۱۰	۲۵	۲۵	۲۵	۲۵	۲۵	۲۵	۲۵	۱۲۴	۲۵	۲۵
۱۰	۱۰	۱۰	۱۰	۲۵	۲۵	۲۵	۲۵	۲۵	۲۵	۲۵	۱۲۴	۲۵	۲۵
۱۰	۱۰	۱۰	۱۰	۲۵	۲۵	۲۵	۲۵	۲۵	۲۵	۲۵	۱۲۴	۲۵	۲۵
۱۰	۱۰	۱۰	۱۰	۲۵	۲۵	۲۵	۲۵	۲۵	۲۵	۲۵	۱۲۴	۲۵	۲۵
۱۰	۱۰	۱۰	۱۰	۲۵	۲۵	۲۵	۲۵	۲۵	۲۵	۲۵	۱۲۴	۲۵	۲۵

$$\sum_{p=0}^{P-1} (N_p \geq N_c) 2^p = LBP_p^R$$
 باتوجه به تصویر و مقدار مرکز به باقی ۱ نسبت می دهیم که نمایان به معادل با عدد ده دوی است که از کنار هم قرار دادن

این اعداد به دست می آید.

$$(0111100)_2 = 124$$

$$(1111111)_2 = 255$$

References:

[https://docs.opencv.org/4.x/dd/d49/tutorial\\_py\\_contour\\_features.html](https://docs.opencv.org/4.x/dd/d49/tutorial_py_contour_features.html)

<https://medium.com/analytics-vidhya/contours-and-convex-hull-in-opencv-python-d7503f6651bc>

[https://docs.opencv.org/3.4/de/d62/tutorial\\_bounding\\_rotated\\_ellipses.html](https://docs.opencv.org/3.4/de/d62/tutorial_bounding_rotated_ellipses.html)

برای یافتن ویژگی **compactness** شکل، محیط و مساحت را می‌ایم. مساحت با تابع **contourarea** بدست آورده می‌شود. محیط نیز با مناسبه فاصله نقاط مجاور شکل و جمع آنها یافته می‌شود. مساحت را در **4p** ضرب و در مربع محیط تقسیم می‌کنیم.

برای یافتن ویژگی **solidity**، مساحت را مانند قسمت قبل یافته، محیط را با دستور **convexhull** که محیط شکل محدب را می‌ایم، مساحت را بر مساحت محدب محیط، تقسیم و خروجی می‌دهیم.

برای یافتن طول محور اصلی و فرعی در تابع **axis\_find**، از تابع **fitellipse** استفاده می‌شود، همچنین جهت شکل را هم می‌دهد. چون ورودی تابع شامل مینیمم 5 نقطه



است، نقاط مرزی را با ترکیب خطی نقاط کانتور پیدا و به **fitellipse** می‌دهیم. مقدار

فروبی این تابع از حاصل تقسیم طول محور فرعی بر اصلی بدست می‌آید.

تابع **info\_contour**، یک کانتور را دریافت و مشخصه‌های آن را با توابع بالا یافته و

در قالب یک **ndarray** فروبی می‌دهد.

تابع **dist\_era**، فاصله بین دو بردار ویژگی با روش اقلیدس را بوسیله **linalg.norm**

محاسبه می‌کنیم. مقادیر اختلاف ویژگی‌های دو بردار را در ضربایی ضرب کرده تا گروه

بندی بهتر انجام شود.

حال برای یافتن و نمایش ویژگی، با توابع بالا به فرم یک ماتریس  $n \times m$  تبدیل کرده

که  $n$  تعداد شکل و  $m$  ویژگی است. در نهایت هم با توابع نشان شده عمل دسته‌بندی را

انجام داده و به هر دسته مشخصه‌ای رنگی معین می‌دهیم.

سوال 3)

## References:

<https://machinelearningmastery.com/using-activation-functions-in-neural-networks/#:~:text=Activation%20functions%20play%20a%20integral,a%20simple%20linear%20regression%20model.>

<https://himanshuxd.medium.com/activation-functions-sigmoid-relu-leaky-relu-and-softmax-basics-for-neural-networks-and-deep-8d9c70eed91e>



## <https://www.aitude.com/comparison-of-sigmoid-tanh-and-relu-activation-functions/>

توابع فعالساز، در شبکه عصبی برای معرفی غیرخطی بودن فروجی هر نورون استفاده می شود. هدف اصلی استفاده از توابع فعالساز، تبدیل فروجی یک نورون به فرم مناسبی است که بتوان از آن به عنوان ورودی لایه بعدی شبکه عصبی استفاده نمود. بدون توابع فعالساز، شبکه عصبی مانند یک مدل رگرسیون خطی است که قادر به آموزش الگوهای غیرخطی پیچیده در دیتاها نیست.

چندین توابع فعالساز مانند آن هایی که در صورت سوال بیان شده داریم که انتخاب تابع فعالساز براساس تسک خاص و ماهیت داده مورد استفاده، بستگی دارد.

تابع فعالساز **sigmoid** تابعی رایج است که بیشتر در لایه فروجی یک شبکه عصبی برای طبقه بندی باینری (**binary classification**) استفاده می شود. مقادیر ورودی در محدوده میان 0 و 1 است که میتوان آن را به عنوان احتمال یک طبقه بندی باینری بیان نمود. این درحالیست که تابع **sigmoid** یک مشکل به صفر رسیدن گرادیان (**vanishing**) که سبب همگرایی کند، در مدت آموزش می شود و میتواند یادگیری الگوهای پیچیده را برای مدل دشوار نماید.

تابع **Tanh** مشابه تابع **sigmoid** است، اما مقادیر ورودی را در محدوده ای بین -1 و 1 نسبت بندی میکند. این تابع فعالسازی میتواند سبب کاهش مشکل به صفر رسیدن گرادیان می شود اما باز هم همان مشکل را دارد.



تابع **ReLU** (واحد قطبی اصلاح شده) تابع فعالسازی است که به دلیل سادگی و کارآمدی کاربرد بیشتری پیدا کرده است و بدین گونه است که تمام ورودی های منفی را صفر کرده، مقادیر ورودی مثبت را نیز بدون تغییر میگذارد. این به شبکه امکان می دهد که سریعتر آموزش ببیند. به این دلیل که از مشکل صفر شدن گرادیان جلوگیری می نماید و سبب نمایش کمتر دیتا ها می شود. با این حال این تابع میتواند مشکل **dying** **ReLU** را داشته باشد. این مشکل سبب می شود بخش بزرگی از شبکه، غیرفعال باشد و یادگیری را متوقف می کند.

تابع **PreLU** گونه ای از تابع **ReLU** است که به جای صفر کردن آن ها، پارامتری قابل یادگیری را به مقادیر ورودی منفی معرفی می نماید. این کار سبب کاهش **dying ReLU** می شود و عملکرد شبکه بهبود می یابد.

در کل توابع **sigmoid** و **Tanh** برای طبقه بندی باینری مناسب اند، توابع **ReLU** و **PreLU** برای آموزش شبکه عصبی عمیق کاربردی تر است و سبب همگرایی سریعتر و عملکرد بهتر میشود.

سوال 4)

References: ta's classes code

Code question

ابتدا دیتاست **mnist** را بارگزاری میکنیم و داده های تست و داده تمرینی را ذخیره میکنیم. بعد داده های تمرینی را به همراه فروبی بررسی و چاپ میکنیم. (در کد هست)



سپس چون داده هایمان بین 0 تا 255 پیسکل اند ، ان را به بازه 0 تا 1 میبریم. همچنین تمام خروجی ها توسط تابع زیرمجموعه keras به فرم one\_hot میبریم.

در دو روش توالی و توابعی، ما لایه های یگسان را می سازیم. لایه هایمان شامل ورودی، **flatten** (ورودی تعریفی از لایه قبلی را از دوبعدی خارج می کند. توسط لایه های **fully connected** قابل دریافت)، لایه پنهانی کاملاً متصل شده با 100 نرون، تابع فعالساز **relu**، و لایه خروجی کاملاً متصل شده که شامل 10 کلاس است و در نهایت با تابع نهایی نرمالایز میکنیم که جمع برابر 1 شه.

در روش توالی یک شی ساخته و لایه ها را افزوده و مدل را کامپایل میکنیم و داده تمرینی را با **fit** آموزش میدهیم. همچنین **epoch** و ارگومان **validation\_split** را مشخص مینماییم. (این ارگومان مقدار برابری که برایش گذاشته است جدا میکند) خروجی داده ها در کد هست. مدلمان دچار **overfit** شده، دلیل اختلاف میان دقت داده تمرینی و **validation**، سادگی داده نسبتاً کوچک هست.

در روش تابعی، تابعی را تعریف کرده و داده های ورودی توسط لایه ای ذخیره شده و لایه های بعدی به شکل تابعی بر روی متغیر اعمال می شود. مزیت این روش نسبت به روش دیگر، امکان اتصال لایه ها با اولویت (ترتیب) غیر ترتیبی است. سپس تابع را فراخوانده و مدلی ساخته و مانند مدل ترتیبی کامپایل کرده و بر روی داده تمرینی آموزش داده و روی داده تست امتحان میکنیم.

دیده می شود به دلیل استفاده از لایه های یکسان ، دو مدل تقریباً عملکردی یکسان دارند.

سوال 5)

### References:

<https://www.analyticsvidhya.com/blog/2021/07/understanding-sequential-vs-functional-api-in-keras/>

<https://medium.com/analytics-vidhya/keras-model-sequential-api-vs-functional-api-fc1439a6fb10>

نه. همه شبکه هایی که با متد **functional** میتوان پیاده سازی کرد، نمی شود با متد **sequential** پیاده سازی نمود. دلیل آن این است که متد **sequential** یک فرم محدود از متد **functional** است که تنها به معماری های خطی **stack** مانند، کاربرد دارد. در واقع لایه ها در یک مدل متوالی به ترتیب پس هم اضافه شده و هر لایه از فروجی لایه قبلی ورودی می گیرد. همچنین متد **functional** انعطاف پذیری بیشتری را در تعریف ساختار معماری شبکه را امکان سازی میکند و مدل های پیچیده تر و غیرخطی را امکان مدل سازی میدهد. همچنین این امکان را فراهم میکند که فروجی یک لایه بتواند به عنوان ورودی چندین لایه بدان متصل شود. این در حالی است که این رفتار در



مدل ترتیبی ممکن نیست و فقط فروجی هر لایه به ورودی لایه بعد در **stack** متصل می شود.

بنابر این دلایل که بیان شد، هر شبکه ای که میتوان با متد ترتیبی (**sequential**) پیاده سازی شود، می تواند با متد **functional** نیز پیاده سازی شود، ولی لزوما برعکس این موضوع صادق نیست. زیرا برخی از شبکه ها برای پیاده سازی کارآمد، به انعطاف پذیری و وضوح (**expressiveness**) متد **functional** نیاز دارند.

سوال 6)

## References: slides class

(الف)

اگر یک کرنل  $7 \times 7$  را با تصویرمان که یک تصویر  $7 \times 7$  با **stride** برابر 1 است استفاده و کانوالو نماییم، فروجی یک ماتریس  $1 \times 1 \times 3$  است. بدلیل اینکه چه در محور افقی و چه در محور عمودی تنها یک بار میتوان لغزاند.

(ب)

اگر تصویر را با سه کرنل  $3 \times 3$  در سه مرحله کانوالو کنیم، ابعاد فروجی بسته به تعداد فیلترهای استفاده شده در هر مرحله دارد. با فرض یکسان بودن تعداد فیلترها در هر مرحله، فروجی یک **tensor** سه بعدی با ابعاد  $3 \times 5 \times 5$  است.

(ج)



استفاده از سه کرنل  $3 \times 3$  در سه مرحله بهتر است. بدین دلیل که این روش به شبکه های عمیق و غیرخطی، امکان یادگرفتن ویژگی های پیچیده تر را می دهد. به علاوه، استفاده از چند کرنل کوچک، سبب ایجاد پارامترهای کمتری نسبت به استفاده از یک کرنل بزرگ در شبکه می شود. در این بخش، استفاده از یک کرنل  $7 \times 7$  سبب ایجاد 147 (7 در 7 در 3) پارامتر می شود. این در حالی است که برای بخش دوم (ب)، تعداد پارامتر برابر 84 پارامتر می باشد. پس استفاده از کرنل کوچک، سبب ایجاد شبکه با ساختاری موثر تر و با کیفیت شده و ویژگی های استخراجی بهتر می باشد.